


Publicaciones y orientaciones para TFI

EJEMPLOS

- ▶ Reducción de características (feature) con clustering k-me
- ▶ Clasificación con *Naïve Bayes* con Validación cruzada 10*1 de Accuracy.
- ▶ Base de datos pública:
<https://archive.ics.uci.edu/dataset/24/activity+recognition+using+smartphones>
- ▶ Varios artículos usan los datos



UC Irvine Machine Learning Repository

Datasets Contribute Dataset About Us Search datasets...

Human Activity Recognition Using Smartphones

Donated on 12/9/2012

Human Activity Recognition database built from the recordings of 30 subjects performing activities of daily living (ADL) while carrying a waist-mounted smartphone with embedded inertial sensors.

Dataset Characteristics	Subject Area	Associated Tasks
Multivariate, Time-Series	Computer Science	Classification, Clustering

Feature Type	# Instances	# Features
-	10299	-

Dataset Information

Additional Information

The experiments have been carried out with a group of 30 volunteers within an age bracket of 19-48 years. Each person performed six activities (WALKING, WALKING_UPSTAIRS, WALKING_DOWNSTAIRS, SITTING, STANDING, LAYING) wearing a smartphone (Samsung Galaxy S II) on the waist. Using its embedded accelerometer and gyroscope, we captured 3-axial linear acceleration and 3-axial angular velocity at a constant rate of 50Hz. The experiments have been video-recorded to label the data manually. The obtained dataset has been randomly partitioned into two sets, where 70% of the volunteers was selected for generating the training data and 30% the test data.

The sensor signals (accelerometer and gyroscope) were pre-processed by applying noise filters and then sampled in fixed-width

Download (58.2 MB)

CITE

3 citations
187181 views

Creators

- Jorge Reyes-Ortiz
- Davide Anguita
- Alessandro Ghio
- Luca Oneto
- Xavier Parra

DOI

10.24432/C54S4K

License

This dataset is licensed under a [Creative Commons Attribution 4.0 International](#) (CC BY 4.0) license.

- Reducción de características (feature) con clustering k-medias.
- Clasificación con *Naïve Bayes classifier*.
- Base de datos pública:
<https://archive.ics.uci.edu/dataset/240/human+activity+recognition+using+smartphones>
- Los experimentos se han llevado a cabo con un grupo de 30 voluntarios de entre 19 y 48 años. Cada persona realizó seis actividades (CAMINAR, SUBIR ESCALERAS, BAJAR ESCALERAS, SENTARSE, ESTAR DE PIE, ACOSTARSE) con un smartphone (Samsung Galaxy S II) colocado en la cintura.
- **K-means clustering based filter feature selection on high dimensional data** By Dewi Ismi, Shireen Panchoo, Murinto Murinto. 2016. Published in International Journal of Advances in Intelligent Informatics.

K-means clustering based filter feature selection on high dimensional data

Dewi Pramudi Ismi^{a,1*}, Shireen Panchoo^{b,2}, Murinto^{c,3}

^a Department of Informatics, Faculty of Industrial Technology, Universitas Ahmad Dahlan, Yogyakarta 55164, Indonesia

^b Department of Business Informatics and Software Engineering, University of Technology, Mauritius

^c Department of Informatics, Faculty of Industrial Technology, Universitas Ahmad Dahlan, Yogyakarta 55164, Indonesia

¹ dewi.ismi@tif.uad.ac.id *; ² s.panchoo@umail.utm.ac.mu; ³ murintokusno@tif.uad.ac.id

* corresponding author

ARTICLE INFO

Article history:

Received February 20, 2016

Revised March 20, 2016

Accepted March 21, 2016

Keywords:

feature selection,
 dimensionality reduction,
 clustering,
 k-means clustering,
 classification,
 high dimensional data

ABSTRACT

With hundreds or thousands of features in high dimensional data, computational workload is challenging. In classification process, features which do not contribute significantly to prediction of classes, add to the computational workload. Therefore the aim of this paper is to use feature selection to decrease the computation load by reducing the size of high dimensional data. Selecting subsets of features which represent all features were used. Hence the process is two-fold; discarding irrelevant data and choosing one feature that representing a number of redundant features. There have been many studies regarding feature selection, for example backward feature selection and forward feature selection. In this study, a k-means clustering based feature selection is proposed. It is assumed that redundant features are located in the same cluster, whereas irrelevant features do not belong to any clusters. In this research, two different high dimensional datasets are used: 1) the Human Activity Recognition Using Smartphones (HAR) Dataset, containing 7352 data points each of 561 features and 2) the National Classification of Economic Activities Dataset, which contains 1080 data points each of 857 features. Both datasets provide class label information of each data point. Our experiment shows that k-means clustering based feature selection can be performed to produce subset of features. The latter returns more than 80% accuracy of classification result.

2

- ▶ Tesis
- ▶ Marco teórico conceptual y definición de variables
- ▶ Construcción del Índice Calidad del Agua (ICA)
- ▶ Varios muestreos y variables
- ▶ ACP relación entre variables y puntos de muestreo

ANÁLISIS DE LA CALIDAD DEL AGUA A PARTIR DE LA CORRELACIÓN ENTRE
VARIABLES FÍSICOQUÍMICAS Y MACROINVERTEBRADOS EN TRES SECTORES DEL
RÍO CANEY, RESTREPO – META.



DANIEL FELIPE GARCÉS RUIZ
LUIS ALEJANDRO PACHECO GUTIÉRREZ



UNIVERSIDAD SANTO TOMÁS
FACULTAD DE INGENIERÍA AMBIENTAL
VILLAVICENCIO
2020

2

Parámetros estudiados con su equipo o técnica y método de medición.

Parámetro	Técnica / Equipo	Medición	Límites de detección
Conductividad E	Multiparámetro	In situ	10us/cm a 2000ms/cm
Oxígeno Disuelto	Multiparámetro	In situ	0,00mg/l a 20,00mg/l
DQO	Medición de sustancias susceptibles a ser oxidadas	Ex situ	No aplica
Solidos suspendidos totales	Laboratorio	Ex situ	No aplica
pH	Medición de potenciales de hidrogeno con multiparámetro	In situ	0,00 a 14,00


Nota: Metodología para toma de datos de las 5 variables por (Garcés, D., Pacheco L., 2020).

Tabla 5.

Clasificación de las aguas y su significado ecológico mediante el índice BMWP.

Clase	Calidad	Valor del BMWP	Significado	Color
I	Buena	≥ 150	Aguas muy limpias	
		123 - 149	Aguas no contaminadas	
II	Aceptable	71 - 122	Ligeramente contaminadas: Se evidencia efectos de contaminación	
III	Dudosa	46 - 70	Aguas moderadamente contaminadas	
IV	Crítica	21 - 45	Aguas muy contaminadas	
V	Muy crítica			

Nota: Clasificación de Alexander Von Humbol



Círculo de correlación de ACP por (Garcés, D., Pacheco L.

Tabla 5.

Clasificación de las aguas y su significado ecológico mediante el índice BMWP.

Clase	Calidad	Valor del BMWP	Significado	Color
I	Buena	≥ 150	Aguas muy limpias	
		123 - 149	Aguas no contaminadas	
II	Aceptable	71 - 122	Ligeramente contaminadas: Se evidencia efectos de contaminación	
III	Dudosa	46 - 70	Aguas moderadamente contaminadas	
IV	Crítica	21 - 45	Aguas muy contaminadas	
V	Muy crítica	<20	Aguas fuertemente contaminadas, situación crítica	

Nota: Clasificación de aguas según su valor BMWP. *Adaptado de* (Instituto de investigación de recursos hídricos, 2011).

Clasificación de la calidad del agua según los valores que tome el ICA.

Categorías de valores que pueden tomar el indicador	Calificación de la calidad de agua	Señal de alarma
0,00 – 0,025	Muy mala	Rojo
0,26 – 0,50	Mala	Naranja
0,51 – 0,70	Regular	Amarillo
0,71 – 0,90	Aceptable	Verde
0,91 – 1,00	Buena	Azul

Nota: Categorías de indicación de calidad de agua según ICA. *Adaptado de* (IDEAM, 2011).

Variables y ponderaciones para el caso de 5 variables.

Variable	Unidad de medida	Ponderación
Oxígeno disuelto	% Saturación	0,2
Sólido suspendidos	mg/l	0,2
Demanda química de oxígeno (DQO)	mg/l	0,2
Conductividad eléctrica	$\mu\text{S}/\text{cm}$	0,2
pH	Unidades de pH	0,2

Nota: Variables de estudio y su ponderación. *Adaptado de* (IDEAM, 2011).

5.1.5. Cálculo del (ICA)

Se calculó el ICA para el caso de las 5 variables para cada uno de los sectores en cada muestra con sus respectivas ponderaciones como se observa en la Tabla 2 y con la siguiente fórmula:

$$ICA_{njt} = (\sum_{i=1}^n W_i \cdot I_{ikjt})$$

- ▶ <https://ojs.latu.org.uy/index.php/INNOTECH/article/view/526>
- ▶ Una técnica precisa de regresiones lineales múltiples (RLM) se utilizó como herramienta avanzada para el modelado y pronóstico de la calidad de las aguas subterráneas. Igualmente, se utilizó el análisis de componentes principales (ACP) para simplificar y comprender la compleja relación entre el agua y los parámetros de calidad.

Modelo de calidad del agua subterránea mediante el uso combinado del análisis de componentes principales (ACP) y regresiones lineales múltiples (RLM)

Caso de estudio: acuíferos de Maturín, Monagas, Venezuela

José Alexander Gil Marín

Departamento de Ingeniería Agrícola, Escuela de Ingeniería Agronómica (EIA), Universidad de Oriente (UDO), Maturín, Estado de Monagas, Venezuela

 <http://orcid.org/0000-0001-9185-0411>DOI: <https://doi.org/10.26461/20.02>**Palabras clave:** antropogénicos, análisis estadístico multivariado, monitoreo ambiental, contaminación

3

- <https://ojs.latu.org.uy/index.php/INNOTEC/article/view/526>
- Construye en indicador calidad del agua
- Descripción de cada componente.
- De 19 variables iniciales con ACP quedan 11 no colineales
- Regresiones lineales múltiples (RLM) con las 11 variables

$$ICA = -39.477 + 6.373 * pH + 0.005 * CE (\mu S/cm) + 9.417 * Fe (mg/l) + 31.618 * Mn (mg/l) + 0.017 * Na (mg/l) + 2.104 * NO_2 (mg/l) + 0.136 * NO_3 (mg/l) + 0.02 * SO_4 (mg/l) + 0.025 * Cl (mg/l) + 6318.54 * Fenol (mg/l) + 0.126 * CF (NMP/100ml) \dots \dots \dots (3).$$

	Componente					
	1	2	3	4	5	6
Temperatura	.114	-.003	.060	.079	.186	.922
pH	.794	.013	.394	.123	-.075	.304
CE	.946	.258	.046	-.017	.111	-.014
TDS	.944	.251	.062	-.033	.111	-.018
Dureza	.973	.195	.052	.041	.013	-.025
Fe	.569	.563	.013	-.045	.023	.194
Ca	.971	.213	.060	.019	.010	.004
Mg						
Mn						
Na						
K						
NO ₂						
NO ₃						
SO ₄						
Cl						
HCO ₃						
Fenol						
CT						
CF						

Tabla 5. Análisis de regresión múltiple para determinar los factores que contribuyen con Índice de calidad del Agua (ICA).

Parámetros	Coficiente β	Error Típico (ET)	β Estandarizado	Posición	t student's	Valor p
(Constante)	-39.477	0.487			-81.102	<0.001a
pH	6.373	0.084	0.053	IV	76.024	<0.001a
CE	0.005	0.001	0.007	VIII	5.905	<0.001a
Fe	9.417	0.436	0.011	VII	21.614	<0.001a
Mn	-31.618	0.434	0.04	V	72.895	<0.001a
Na	0.017	0.003	0.003	X	5.107	<0.001a
NO ₂	2.104	0.01	0.105	III	217.646	<0.001a
NO ₃	0.136	0.004	0.014	VI	32.413	<0.001a
SO ₄	0.02	0.005	0.002	XI	3.731	<0.003a
Cl	0.025	0.003	0.006	IX	7.526	<0.001a
Fenol	6318.542	10.973	0.332	II	575.81	<0.001a
CF	0.126	0	0.95	I	1919.101	<0.001a

a. Altamente significativo

- ▶ DOI:
<https://doi.org/10.21919/remef.v18i4.926>
- ▶ Series de tempo.
- ▶ Reduccion de características com ACP
- ▶ Análisis antes y después de crisis

Ciclos en el Sector Bancario Mexicano: un Índice Coincidente (CP1G7)¹ vía ACP²

Andrés Giovanni Camacho Ardila³  - Universidad Nacional Autónoma de México, México
Federico Hernández Álvarez  - Universidad Nacional Autónoma de México, México
Luis Ignacio Román de la Sancha - Universidad Nacional Autónoma de México, México

Resumen

Se propone construir un índice acerca de los ciclos financieros del sector bancario en México, usando métricas de desempeño del G7 y el ACP. Se compara este indicador con los ciclos económicos y financieros nacionales, así también se analiza el comportamiento de las métricas antes, durante y después de la crisis financiera Subprime y la crisis sanitaria COVID19. Se encontró que el Componente Principal 1 del G7 (CP1G7) es un indicador adecuado para medir el estado (recesión o expansión) que guarda el sistema bancario mexicano, así también, el ACP permitió identificar las variables que más impactan en cada periodo. No existe a nivel nacional un indicador acerca de los ciclos del sector bancario, ni un análisis de las métricas en periodos de crisis. El modelo no incluye variables exógenas (económicas o financieras). En conclusión, tanto el índice CP1G7 como el análisis de la dinámica de las métricas bancarias, son herramientas útiles para la detección temprana de posibles amenazas para la estabilidad financiera.

Clasificación JEL: C02, C10, C63, C65, E32, G10, G19, G21.

Palabras clave: Análisis de Componentes Principales, Crisis Financieras, Ciclos Económicos, Ciclos Financieros, Indicador Coincidente.

4

► DOI:
<https://doi.org/10.21919/remef.v18i4.926>

3.1 Cálculo de métricas

Las métricas que se utilizaron para realizar el ACP fueron calculadas a partir de las series históricas de la CNBV, estas series incluyen rubros del Balance General y del Estado de Resultados, así como ratios ya calculadas como el ROE, ROA, Índice de Morosidad, entre otros; con esta información se computaron métricas que permiten comprobar el comportamiento de las instituciones bancarias a través del tiempo, como lo proponen Gogas, Papadimitriou y Agrapetidou (2018). Se trabajó el G7 y los bancos que lo componen.





Figura 8. Distribución de observaciones y variables en los Componentes Principales para el G7.
 Fuente: Elaboración propia con series históricas de la CNBV.

- ▶ Para cada encuestado se identificaron el sexo, el rol desempeñado en el proceso enseñanza-aprendizaje (estudiante/docente) y la carrera técnica a la que está vinculado (arquitectura/ingeniería).
- ▶ Dado que las 60 preguntas estaban estructuradas en cuatro categorías y las respuestas estaban valoradas de 1 a 4, según se ha indicado (Nunca = 1; A veces = 2; Casi siempre = 3; y Siempre = 4), los valores obtenidos en cada una de las preguntas asociadas a cada una de las categorías fueron sumados

Evaluación Bidireccional del Proceso Enseñanza-Aprendizaje Universitario Aplicando Análisis de Componentes Principales

Borja Velázquez-Martí^{a*}, Juan José Pérez-Arévalo^b

^a Departamento de Ingeniería Rural y Agroalimentaria, Universidad Politécnica de Valencia (Spain), borvemar@dmta.upv.es, ^b Facultad de Ingeniería, Universidad Católica de Santiago de Guayaquil (Ecuador), obras.civiles.perez.perez@gmail.com.

Abstract

The evaluation of education systems in most universities is based on the analysis of the exclusive assessment of the students, which are subject to some surveys where they are asked about their perceptions on various aspects of the organization, methodology, motivation raised by the teacher, and evaluation system. However, there may be discrepancies between the perception of teachers and students, which are not sometimes considered in the evaluation processes of the system. This paper proposes the hypothesis that the teaching-learning process is positively developed if it is simultaneously highly valued by both groups. The applicability of Principal Component Analysis as method of assessment of the appreciation of educational process based on surveys of teachers and students has been demonstrated, and it allows to identify the need for corrective actions.

- Dado que las 60 preguntas estaban estructuradas en cuatro categorías y las respuestas estaban valoradas de 1 a 4, según se ha indicado (Nunca = 1; A veces = 2; Casi siempre = 3; y Siempre = 4), los valores obtenidos en cada una de las preguntas asociadas a cada una de las categorías fueron sumados

Tabla 1. Categorización de las entrevistas.

No.	Categorías	Subcategorías
01	Organización en el aula	1. Organización del aula. 2. Como organizan y trabajan los docentes con sus alumnos.
02	Metodologías de estudio	1. El modo como el docente organiza a sus alumnos. 2. De las metodologías, entre ellas las Tics. 3. De la ejecución de las tareas. 4. Ante las posibles dificultades. 5. Del trabajo con sus alumnos. 6. De las tareas con sus alumnos.
03	Estrategias de motivación	1. Motivación del alumnado. 2. De la explicación a sus alumnos. 3. Al encargar una tarea para la casa a sus alumnos. 4. Del proceso para resolver las tareas.
04	Estrategias de evaluación	1. El uso de las distintas formas de evaluación. 2. De las metas y objetivos que se persiguen.

Tabla 3. Coeficientes de las ecuaciones (1 y 2) que forman cada componente

	F1	F2	F3	F4
Organización	0,389	0,902	0,171	-0,074
Metodología	0,541	-0,099	-0,384	0,742
Motivación	0,536	-0,195	-0,480	-0,666
Evaluación	0,518	-0,372	0,770	-0,029

$$F1 = 0,5181 * \text{Evaluación} + 0,5411 * \text{Metodología} + 0,536208 * \text{Motivación} + 0,3891 * \text{Organización} \quad (1)$$

El segundo componente principal F2 tiene la ecuación (2).

$$F2 = -0,372 * \text{Evaluación} - 0,099 * \text{Metodología} - 0,195 * \text{Motivación} + 0,902 * \text{Organización} \quad (2)$$

5

- ▶ Estudiando la **contingencia** de cada una de las **sub-categorías estudiadas**, es decir, los porcentajes de cada uno de los valores obtenidos en las respuestas de los docentes y estudiantes de arquitectura e ingeniería en cada una de las categorías (**organización del trabajo en el aula; metodologías de trabajo; estrategias de motivación y estrategias de evaluación**), donde se evalúa la percepción que tienen los profesores y los estudiantes en cada una de ellas.

Tabla 3. Coeficientes de las ecuaciones (1 y 2) que forman cada componente

	F1	F2	F3	F4
Organización	0,389	0,902	0,171	-0,074
Metodología	0,541	-0,099	-0,384	0,742
Motivación	0,536	-0,195	-0,480	-0,666
Evaluación	0,518	-0,372	0,770	-0,029

$$F1 = 0,5181 * \text{Evaluación} + 0,5411 * \text{Metodología} + 0,536208 * \text{Motivación} + 0,3891 * \text{Organización} \quad (1)$$

El segundo componente principal F2 tiene la ecuación (2).

$$F2 = -0,372 * \text{Evaluación} - 0,099 * \text{Metodología} - 0,195 * \text{Motivación} + 0,902 * \text{Organización} \quad (2)$$

- ▶ Base de datos pública: mPower
- ▶ 2253 fonación de /a/, 62 Variables.
- ▶ Selección de variables: ACP, Diferencia de Medias.
- ▶ Clasificación EP y NEP
- ▶ Clasificación con:
 - ▶ Multilayer Perceptron (MLP) and Logistic Regression (LR) neural networks
- ▶ Calidad: area under receiver operating characteristic curve, AUC-ROC, over 0.82.

Selection of voice parameters for Parkinson's disease prediction from collected mobile data

Monica Giuliano
Engineering Departament
Universidad Nacional de La Matanza
San Justo, Argentina
mgiuliano@unlam.edu.ar

Francisco Díaz Pérez
Escuela Técnica Superior de Ingeniería
Universidad Politécnica de Madrid
Madrid, Spain
fdiaz@etsisi.upm.es

Alfonsa García-López
Escuela Técnica Superior de Ingeniería
Universidad Politécnica de Madrid
Madrid, Spain
alfonsa.garcia@etsisi.upm.es

Osvaldo Sposito
Engineering Departament
Universidad Nacional de La Matanza
San Justo, Argentina
sposito@unlam.edu.ar

Silvia Pérez
Engineering Departament
Universidad Nacional de La Matanza
San Justo, Argentina
sperez@unlam.edu.ar

Julio Bossero
Engineering Departament
Universidad Nacional de La Matanza
San Justo, Argentina
jbossero@unlam.edu.ar

Abstract— Voice disorders, which can help in the diagnosis of Parkinson's disease (PD), can be measured with acoustic tools. In this work, demographic data and vocal phonation records /a/ from the available mPower database were analyzed to identify PD patients. A parsimonious model was then found that achieved a reduction from 62 to 5 phonation characteristics, which were considered in addition to gender and age. Multilayer Perceptron (MLP) and Logistic Regression (LR) neural networks were used to obtain a model with high prediction capacity (area under receiver operating characteristic curve, AUC-ROC, over 0.82). This work contributes to the monitoring of EP patients from the recording of a few phonation features collected by means of a mobile phone.

Keywords—Parkinson disease, voice parameters, mobile data, classification models.

The current study utilized an open-access dataset named “mPower” available at <https://www.synapse.org/>. Synapse is a platform that allows scientific content sharing (data, code, results). The Synapse mPower (*Mobil Parkinson Disease Study*) is an observational smartphone-based ongoing study that pilots new approaches to monitoring key indicators of PD progression and diagnosis. It supplements traditional behavioral symptom measurements with novel metrics from sensor-rich mobile devices. As a scalable, inexpensive, and non-invasive method for frequent measurement and tracking of symptoms, the Parkinson's mPower app has been able to survey a large, longitudinal cohort of volunteers with PD and healthy controls, who provide their voice recordings and demographic data, and do several memory, tapping and walking activities [12]

Demographic data and recordings of the /a/ vowel

Selection of voice parameters for Parkinson's disease prediction from collected mobile data

- ▶ Base de datos pública: mPower
- ▶ 2253 fonación de /a/, 62 Variables.
- ▶ Selección 5 variables, genero y edad, momento de la medicación
- ▶ Clasificación con:
 - ▶ Multilayer Perceptron (MLP) and Logistic Regression (LR) neural networks
- ▶ Calidad: area under receiver operating characteristic curve, AUC-ROC,
 - ▶ 0.826 MLP.
 - ▶ 0,83 RL




Fig. 1. MLP model: ROC curve

Fig. 2. L R Model

TABLE II. SUMMARY OF THE RESULTS CONSIDERING MLP AND RL

Number of voice variables /parameters	Independent variables	AUC MLP	AUC LR
5	sex / age	0.826	0.832
5	Sex / age /medication time point	0.972	No converge

- ▶ Base de datos propia EP y NEP → $n=108$
- ▶ Publicada y libre
- ▶ Inicialmente 339 variables propuestas por autor Tsanas 2012.
- ▶ Selección de variables 11: ACP, diferencia de medias, modelos de regresión (LASSO, Elasticnet).
- ▶ Comparación de resultados con el autor de 10 variables.

Selección de Medidas de Disfonía para la Identificación de Enfermos de Parkinson

Selection of Dysphonia Measures for the Identification of Parkinson's Disease

Monica Giuliano
Engineering Department
Universidad Nacional de La Matanza
San Justo, Argentina
mgiuliano@unlam.edu.ar

Luis Fernandez
Engineering Department
Universidad Nacional de La Matanza
San Justo, Argentina
lfernandez@yahoo.com.ar

Silvia Pérez
Engineering Department
Universidad Nacional de La Matanza
San Justo, Argentina
sperez@unlam.edu.ar

Resumen— La naturaleza no invasiva del análisis del habla en pacientes con enfermedad de Parkinson (EP) lo convierte en una herramienta importante para la detección y monitoreo de la enfermedad. A partir de registros propios de 108 personas, con EP y sin EP, en este trabajo se estimaron 297 medidas de disfonía. Se las clasificó según cuatro grupos que caracterizan diferentes patologías en la voz: dos grupos asociados con la periodicidad de la señal, un grupo asociado a problemas de ruido por cierre incompleto de las cuerdas vocales y un último grupo, relacionado con dificultades en el posicionamiento de los articuladores en el tracto vocal. Se realizó una preselección de 35 medidas atendiendo a la multicolinealidad presente entre el conjunto total y variables consideradas relevantes por los autores de referencia. La utilización de algoritmos de estimación penalizada para la selección de variables, en modelos de regresión logística, permitió obtener modelos cuyas capacidades predictivas promedio superaron el 80%. Los resultados de este estudio permiten obtener una clasificación jerárquica de medidas de disfonía, importantes para la detección y monitoreo del EP con técnicas no invasivas.

I. INTRODUCCION

El análisis de la voz de pacientes con Enfermedad de Parkinson (EP) ha sido de interés en las últimas décadas. Este tema ha reunido a un grupo interdisciplinario integrado por médicos de hospitales públicos de Argentina e investigadores de la Universidad Nacional de La Matanza (UNLaM) de diferentes áreas. En este contexto, se construyeron dos bases de datos de fonaciones de personas con y sin EP cuyas características evidencian fuertes diferencias en medidas de disfonía de la voz. En trabajos anteriores [1], se mostraron algunos resultados cualitativos respecto del conjunto de datos reunido.

En pacientes con EP se da una combinación de deficiencias en el control de las vías respiratorias superiores, la laringe y los músculos respiratorios. Es común que pacientes con EP presenten disartria [2, 3, 4] entre los síntomas que afectan la voz. La naturaleza no invasiva del análisis del habla lo convierte en una herramienta atractiva

- Inicial 339 variables según teoría
- Selección ACP y dif de medias:33
- Lasso, elasticnet → 11 var
- Comparación otro autor
- Intervalos de confianza EP y NEP

Tabla 1: Clasificación de las 339 medidas de disfonía.

Grupo	Medidas	Variables	Cantidad
G1	Variaciones de F0	V1-V22, V49-V51, V155-336, V337, V339	209
G2	Variaciones de la amplitud	V23-V44	22
G3	Ruido	V45-V48, V52-V70, V338	24
G4	Problemas en la articulación	V71-V154	84

Tabla 6: Frecuencia promedio de aparición de las 11 variables más relevantes según los 4 modelos (2 LASSO - 2 elastic net) y según grupo de clasificación (50 iteraciones por modelo).

Grupo	Variable	% de veces que queda elegida cada variable en los modelos (de 50 iteraciones)				Promedio
		LASSO		elastic net		
		modelo 1L	modelo 2L	Modelo 1e	Modelo 2e	
G1	V1	26	12	22	40	25
	V51	56	18	28	18	30
G2	V34	70	40	48	58	54
G3	V338	96	92	98	100	96.5
	V59	70	22	26	42	40
	V70	36	10	10	42	24.5
G4	V137	96	92	96	100	96
	V141	90	62	80	90	80.5
	V152	96	94	100	100	97.5
	V71	66	26	36	54	45.5
	V75	98	92	96	100	96.5

Tabla 8: Intervalo de Confianza (IC) para las 11 medidas seleccionadas como más relevantes según Enfermo y no Enfermo con Parkinson (E y noE) y según grupo de clasificación de la medida de disfonía y p-valor para diferencia de media. (N-E: 46, N-noE: 62)

Grupo	Variable	E - IC(95%)	noE - IC(95%)	p-valor
G1	V1	[0.47; 0.87]	[0.3; 0.41]	0.003
	V51	[2.01; 5.59]	[0.64; 2.61]	0.0354
G2	V34	[0.08; 0.1]	[0.07; 0.08]	0.0019
G3	V338	[0.68; 0.72]	[0.62; 0.65]	<0.0001
	V59	[0.00057; 0.0016]	[0.00047; 0.00092]	0.1689
	V70	[0.16; 0.17]	[0.14; 0.15]	0.0006
	V137	[0.04; 0.04]	[0.03; 0.03]	<0.0001
G4	V141	[0.01; 0.02]	[0.01; 0.01]	0.0003
	V152	[0.02; 0.02]	[0.01; 0.01]	<0.0001
	V71	[9.24; 9.57]	[8.94; 9.25]	0.0083
	V75	[-0.09; 0.68]	[-1.24; -0.69]	<0.0001

Tabla 5: Indicadores del área bajo la curva ROC para cada modelo considerado en las 50 iteraciones.

	Min AUC	Max AUC	Promedio AUC
Modelo 1L	0.60	0.93	0.82
Modelo 2L	0.65	0.94	0.80
Modelo 1E	0.69	0.97	0.83
Modelo 2E	0.70	0.98	0.84

Tabla 7: Once variables seleccionadas relevantes en orden decreciente de importancia, según grupo de clasificación y coincidencia o no con selección de [8].

Orden de importancia	Grupo	Variable	Promedio	Preselección	
				Propia	Ambos
1	G4	V152	0,975	x	
2	G3	V338	0,965		x
3	G4	V75	0,965		x
4	G4	V137	0,96	x	
5	G4	V141	0,805	x	
6	G2	V34	0,54		x
7	G4	V71	0,455		x
8	G3	V59	0,4	x	
9	G1	V51	0,3	x	
10	G1	V1	0,25		x
11	G3	V70	0,245		x

Análisis comparativo entre CNN y Modelos Logísticos para detección de la Enfermedad de Parkinson utilizando la voz.

Renata S. Guatelli¹, Monica Giuliano², Verónica Aubin¹, Luis Fernández¹,
María Laura Pepe¹, Silvia N. Pérez^{1,2}

¹Universidad Nacional de La Matanza, ²Universidad Nacional del Oeste
¹rguatelli@unlam.edu.ar, ²mgiuliano@uno.edu.ar

- Comparación de algoritmos con diferentes medidas de Calidad

Indicador	Fórmula
ACC: Accuracy o Exactitud	$(TP + TN) / TOTAL$
Tasa de Error	$(FP + FN) / TOTAL = 1 - ACCURACY$
TPR Sensibilidad o tasa de verdaderos positivos	$TPR = TP / (TP + FN) = 1 - FNR$
TNR Especificidad Tasa de Verdaderos Negativos	$TNR = TN / (TN + FP) = 1 - FPR$
Exactitud Balanceada o Balanced Accuracy	$(TPR + TNR) / 2$

Resumen

En las últimas décadas se ha estudiado el habla de personas con Enfermedad de Parkinson (EP) diferenciándose del habla de personas sin EP, lo que resulta interesante por ser un método no invasivo que podría ser útil para el diagnóstico y seguimiento de los pacientes. Aquí proponemos dos técnicas de clasificación muy distintas para el análisis de la misma base de datos de 135 audios. Cada técnica fue presentada por los autores en trabajos anteriores y aquí se describen y comparan para la clasificación de los audios según condición de enfermedad, con EP y sin EP. La primera técnica toma una selección de 11 variables utilizando medidas acústicas de la señal de audio y clasifica los audios con modelos logísticos. La segunda utiliza la imagen del espectrograma producida con los audios y clasifica con redes neuronales convolucionales (CNN). Los resultados se comparan utilizando diferentes indicadores (sensibilidad, especificidad, exactitud, tasa de

FNR: Tasa de Errores o Tasa De Falsos Negativos	$FNR = FN / (FN + TP) = 1 - TPR$
FPR Tasa de Caída o Tasa de Falso Positivos	$FPR = FP / (FP + TN) = 1 - TNR$
PPV Precisión o Valor Predictivo Positivo	$PPV = TP / (TP + FP) = 1 - FDR$
NVP Valor Predictivo Negativo	$NVP = TN / (TN + FN) = 1 - FOR$
FDR Tasa de Descubrimiento Falso	$FDR = FP / (FP + TP) = 1 - PPV$
FOR Tasa de Falsas Omisiones	$FOR = FN / (FN + TN) = 1 - NVP$
F1 Score	$F1 = 2 * [2 TP / (2 * TP + FP + FN)] = (PPV + TPR) / (PPV + RPR)$
Coefficiente de Correlación de Matthews	$MCC = [(TP * TN) - (FP * FN)] / \sqrt{ (TP + FP) * (TP + FN) * (TN + FP) * (TN + FN) }$
Razón de verosimilitud positiva (LR+)	$LR+ = TPR / (1 - TNR) = TPR / FPR$
Razón de verosimilitud	$LR- = (1 - TPR) / TNR =$

Otras publicaciones: Puntos destacados

- ▶ Comparación de algoritmos con diferentes medidas de Calidad en la misma base
- ▶ Modelo de Regresión Logística (RL) a partir de 11 medidas seleccionadas.
- ▶ Modelo CNN (Redes Neuronales Convolucionales) a partir de la imagen de los espectogramas)




Tabla 7. Índices obtenidos en la evaluación de la clasificación según el modelo logístico y el modelo CNN Alexnet

Indicador	Modelo Logístico	CNN ALEXNET
ACC exactitud	0,85	0,88
Tasa de Error	0,15	0,12
TPR Sensibilidad	0,79	0,87
TNR Especificidad Tasa de Verdaderos Negativos	0,91	0,89
Exactitud Balanceada	0,85	0,88
PPV Precisión o Valor Predictivo Positivo	0,88	0,88
NVP Valor Predictivo Negativo	0,83	0,88
F1 Score	0,83	0,87
Coefficiente de Correlación de Matthews	0,71	0,76
FDR Tasa de Descubrimiento Falso	0,21	0,13

9 Publicación tesis doctoral: Puntos destacados (para ver por separado)

- ▶ Base de datos EP-NEP → 55-55
- ▶ Definición de variables
- ▶ Selección de variables con SVM con validación cruzada con accuracy promedio y desvío.
- ▶ Definición de Modelos de 3 Dimensiones (3D)
- ▶ Clasificación con;
 - ▶ SVM polinomial
 - ▶ SVM Radial
 - ▶ KNN
 - ▶ Randon Forest
- ▶ División Training – Test 80%-20%
- ▶ Medidas de calidad: Accuracy promedio, F1 y AUC
- ▶ Comparacion con Modelos de 10 D de otros autores
- ▶ Comparacion modelo 3D con otras bases de datos



STATISTICS, OPTIMIZATION AND INFORMATION COMPUTING
Stat., Optim. Inf. Comput., Vol. x, Month 202x, pp 0–23.
Published online in International Academic Press (www.IAPress.org)

Using reduced feature space (2D and 3D) based on entropic measures for detecting Parkinson's disease through voice

Mónica Giuliano ^{1,2,4} Luis Alberto Fernández ^{1,3} Walter Legnani ⁴

¹*Institute of Health Sciences, Universidad Nacional del Oeste, San Antonio de Padua, Argentina*

²*Experimental Computing Research and Development Laboratory, Universidad Nacional de Hurlingham, Villa Tesei, Argentina*

³*Department of Engineering and Technological Research, Universidad Nacional de La Matanza, San Justo, Argentina*

⁴*Signal and Image Processing Center, Facultad Regional Buenos Aires, Universidad Tecnológica Nacional, Ciudad Autónoma de Buenos Aires, Medrano 951, Argentina*

Abstract

This research presents a proposal for the integration of different fields, including Parkinson's disease (PD) detection, acoustic voice analysis, and signal processing. The proposal entails the development of two and three dimensional parsimonious models, predicated on feature spaces constituted by variants of Shannon's permutation entropy and autocorrelation measures. These models elucidate the structural and informative nature of vocal signals in individuals with and without the disease (PD-NPD). The reduced-dimensional feature spaces (2D and 3D) are novel and were used for the automatic classification of voices using support vector machines (SVM) with polynomial kernels and cross-validation, achieving average accuracy values between 0.82 and 0.88. Furthermore, the identification of homogeneous subgroups according to the coordinates in the space of 2D characteristics represents significant progress. The variables under consideration are candidates for biomarkers of subtypes of speech disorders for Parkinson's disease. The database used is freely accessible to facilitate reproducibility. The results obtained are compared with a selection of variables proposed by other authors and also with independent databases. The proposed approach is simple and precise and shows promise for the diagnosis and monitoring of PD through the effective use of samples of the vowel /a/ of just one second with a reduced feature space that could improve clinical workflows.

Keywords Parkinson's Disease, Voice, Autocorrelation, Weighted Permutation Entropy, Band Spectral Entropy.

9 Publicación tesis doctoral: Puntos destacados (para ver por separado)

- Base de datos EP-NEP → 55-55
- Definición de variables
- Selección de variables con SVM con validación cruzada con accuracy promedio y desvío.
- Definición de Modelos de 3 Dimensiones (3D)

Table 2. Variable names and parameters of the features explored.

Variables	Name	Parameters explored
WPE	Weighted Permutation Entropy	m: 3 to 6; tau: 1 to 15
AC	Autocorrelation	lag: 1 to 50
PE	Permutation Entropy	m: 3 to 6 tau: 1 to 15
SlopePE	Slope Entropy	m: 3 to 6; tau: 1 to 15
SE	Total Spectral Entropy	-
BSEi	Band Spectral Entropy	Bands between: 0, 500, 1000, 2000, 3000, 4000, 5000, 6000, 7000, 8000 Hz.
AWPE	Amplitude Weighted Permutation Entropy	m: 3; tau: 1 to 15
FWPE	Frequency Weighted Permutation Entropy	m: 3; tau: 1 to 15

Table 1. Demographic characteristics of the participants and clinical condition of patients with PD. Mean (deviation) is indicated.

Condition	#	Age (years)	Illness period (years)	UPDRS III	H&Y	Levodopa (mg)
PD	55	64.09 (8.24)	6.11 (3.89)	30.35 (11.17)	1.59 (0.59)	880.19 (479.22)
NPD	55	59.95 (11.59)				

2.2. Autocorrelation and entropy measures

Several signal measures were calculated on the database, with the aim being to find the ones that would best help to differentiate the classes of interest, i.e. subjects with PD and NPD.

The autocorrelation (AC) of a signal is a measure of the similarity between the signal and a lagged version of itself and was proposed by [26, 27].

Mathematically, the normalized autocorrelation $r_{xx}(l)$ of a discrete signal subtracting its mean value is:

$$r_{xx}(l) = \frac{\sum_{n=-\infty}^{\infty} (x_n - me)(x_{n-l} - me)}{\sum_{n=-\infty}^{\infty} (x_n - me)^2}, \quad (1)$$

where l is the time lag (or lag) and x_n represents the signal at time t_n , where n is the time index that spans the full range of the signal and me is the mean value.

In information theory, Shannon's entropy [28, 29] measures the uncertainty of a message or information source. It can be considered as the average amount of information contained in the symbols associated with the source. If a message source produces N symbols S_i , with probability of occurrence p_i , Shannon's entropy is calculated by the expression:

$$H = - \sum_{i=1}^N p_i \ln(p_i). \quad (2)$$

If all symbols are equiprobable, the entropy reaches its maximum value, $H = \ln(N)$, and if the probability is concentrated in a few symbols it takes small values.


Permutation entropy (PE) of a signal provides a measure of the predictability of the data series comprising it. The probability is calculated in a specific way. Given a time series $(x_1, x_2, x_3, \dots, x_N)$ the m -tuples are

9 Publicación

- Definición de variables
- Definición de Modelos de 3 Dimensiones (3D)
- Selección de variables con SVM con validación cruzada con accuracy promedio y desvio.
- División Training – Test 80%-20%
- Medidas de calidad: Accuracy promedio, F1 y AUC

Models		Polynomial SVM hyperparameters with 80% training (N=88) (d - γ - C)	Quality measures with the 20% test (N=22)		
			Acc	F1score	AUC
Model 1	WPE $\times$ AC	3 - 0.1 - 0.5	0.773	0.706	0.818
Model 2	WPE $\times$ AC $\times$ BS4	1 - 0.1 - 0.5	0.864	0.842	0.909
Model 3	WPE $\times$ AC $\times$ AWPE	2 - 0.1 - 1	0.818	0.778	0.892
Model 4	WPE $\times$ AC $\times$ F2WPE	3 - 0.1 - 0.5	0.818	0.778	0.818
Model 5	WPE $\times$ AC $\times$ F1WPE	2 - 0.1 - 1	0.773	0.737	0.810
Model 6	WPE $\times$ AC $\times$ PE	2 - 0.1 - 1	0.727	0.625	0.810

Model	3rd variable	Variable name	Selected parameters	Mean Acc (Max obtained)	Deviation
Model 2	Spectral entropy by bands	BSE4	Spectral Band 4 between 2000 and 3000 Hz	0.879	0.094
Model 3	Entropy on amplitude curve	AWPE	m=3, tau=2	0.867	0.102
Model 4	F2WPE Entropy on F2 frequency curve	F2WPE	m=3, tau=9	0.843	0.103
Model 5	Entropy on F1 frequency curve	F1WPE	m=3, tau=15	0.841	0.094
Model 6	Permutation Entropy	PE	m=6, tau=13	0.835	0.111
Model 7	Spectral entropy	SE	-	0.824	0.097
Model 8	SlopePE – Slope entropy	SlopePE	m=6, tau=7	0.830	0.119
Model 9	Entropy on F0 frequency curve	F0WPE	m=3, tau=13	0.821	0.107



9 Publicación tesis doctoral: Puntos destacados (para ver por separado)

- Comparacion con Modelos de 10 D de otros autores.

Table 12. For the HUNIPA dataset. Variable groups (FS) and mean Acc and standard deviation for the classification using SVM with a polynomial kernel (1) to (7). CNN classification (8) and (9).

Variable selection technique	Model dimension	Mean Acc	Deviation
(1) mRMR [14]	10D	0.703	0.123
(2) GSO [14]	10D	0.657	0.140
(3) Relief [14]	10D	0.702	0.103
(4) LASSO [14]	10D	0.602	0.114
(5) Ensemble ranking [14]	10D	0.673	0.091
(6) Tsanas et al. [13]	10D	0.712	0.123
(7) Giuliano et al. [15]	11D	0.850	0.112
(8) Guatelli et al. [53]	CNN	0.839	–
(9) Guatelli et al. [53]	EML	0.800	–
This research in Model 2	3D (WPE × AC × BSE)	0.879	0.094

- Comparacion modelo 3D con otras bases de datos

Table 13. The mean and standard deviation of accuracy (Acc.) were calculated for the three features with the same parameters Model 2 (WPE × AC × BD4) and Model 10 (WPE × AC × BD7). These metrics were evaluated separately for each corpus (HUNIPA, GITA and Neurovoz) for the vowel /a/ (in 1 second of phonation) separately and all together. .

Database	Model	Mean Acc.	Deviation	Name	Selected parameters
HUNIPA	Model 2	0.879	0.094	AC WPE BSE4	lag = 13 m = 6, τ = 13 Band 4: 2000–3000 Hz
HUNIPA	Model 10	0.846	0.099	AC WPE BSE4	lag = 13 m = 6, τ = 13 Band 7: 6000–8000 Hz
GITA	Model 10	0.711	0.136	AC WPE BSE7	lag = 13 m = 6, τ = 13 Band 7: 6000–8000 Hz
NeuroVoz	Model 10	0.708	0.124	AC WPE BSE7	lag = 13 m = 6, τ = 13 Band 7: 6000–8000 Hz
Mixed datasets	Model 10	0.724	0.068	AC WPE BSE7	lag = 13 m = 6, τ = 13 Band 7: 6000–8000 Hz

Trabajo Final Integrador: TFI

- ▶ Objetivo claro y abordable en 6 meses

- ▶ Acotados, abordables

- ▶ Bases de datos

- ▶ Metodologías de ciencia de datos:

- ▶ *Clasificación*
 - ▶ *Exploración e identificación de Patrones*
 - ▶ *Predicción*
 - ▶ *Otras.*

- ▶ Comparación de distintas técnicas con la misma base.


- ▶ Comparación de la misma técnica en diferentes bases.

- ▶ Comparación con resultado de otro autor/es (base de datos o técnicas).

1. Plan de TFI
2. Orientaciones del Comité Académico
3. Asignación de un Tutor
4. Ajuste del TFI

ORIENTATIVO


WEB Mininig: Prof. Enrique Fernández



WEB Minig: Prof Fernández

- <https://docs.google.com/presentation/d/1TX36KADNgi2FCFRDIs13DUtyfSzoZ5F/edit?slide=id.p6#slide=id.p6>


Preparación de Datos para la Valoración de Propiedades



WEB Minig: Prof Fernández

► <https://s13DUt>

Modelos de Predicción



Trabajo Final Integrador: TFI

Orientaciones

- ▶ Bases de datos: Disponibilidad:
 - ▶ inmediata, ya
 - ▶ pocos meses
 - ▶ en búsqueda;
 - ▶ Construcción...
- ▶ Metodologías de ciencia de datos:
 - ▶ *Clasificación*
 - ▶ *Exploración e identificación de Patrones*
 - ▶ *Predicción*
 - ▶ *Otras.*

- ▶ **Link para indicar estado actual y poder buscar tutor en el siguiente link**

<https://docs.google.com/spreadsheets/d/14wlnlUllt7FAoyoxyKAPFmDnwGW0Tmul76M4rWMhVwA/edit?gid=372543135#gid=372543135>

1. Plan de TFI
2. Orientaciones del Comité Académico
3. Asignación de un Tutor
4. Ajuste del TFI

Trabajo Final Integrador: TFI (orientaciones)

- ▶ Tiempos: 1 AÑO FINALIZADA LA CURSADA
- ▶ Suelen ser más largos de los previstos
- ▶ 6 MESES:
 - ▶ Bases de datos: Disponibilidad inmediata
 - ▶ Limpieza y preparación de datos → lleva tiempo
 - ▶ Análisis
 - ▶ Metodologías de ciencia de datos ya utilizadas o no muy diferentes.
- ▶ 4 MESES:
 - ▶ *Elaboración de informe → demanda tiempo y lectura del tutor*

ORIENTATIVO

Considerar:

- ▶ Estudio de casos
- ▶ Ejemplos de trabajos realizados en las materias.
- ▶ No es tesis doctoral ni de maestría.
- ▶ Se puede basar en un paper publicado.
- ▶ La teoría del dominio del tema no se desarrolla se toma de terceros (por ejemplo contaminación del agua tomo variables propuestas por expertos y analizo la base de datos con alguna novedad).
- ▶ La novedad puede ser mínima:
 - ▶ Ajuste de un parámetro....,
 - ▶ Ampliar a otra base de datos...
 - ▶ Cambiar la base de datos...
 - ▶ Usar nuevas variables...
 - ▶ Comparar varias técnicas y varias medidas de calidad....
 - ▶ ...

ORIENTATIVO

Trabajo Final Integrador: TFI

- ▶ Enviar Resumen
- ▶ Bases de datos: Disponibilidad:
- ▶ Metodologías tentativa
 - ▶ *Dada en la especialización;*
 - ▶ *Se apoya en temas dados*

▶ **Agregar info en NOVIEMBRE**

para indicar estado actual y poder buscar tutor en el siguiente link

<https://docs.google.com/spreadsheets/d/14wlnlUllt7FAoyoxyKAPFmDnwGW0Tmul76M4rWMhVwA/edit?gid=372543135#gid=372543135>

1. Plan de TFI
2. Orientaciones del Comité Académico
3. Asignación de un Tutor
4. Ajuste del TFI

- ▶ Directora:
- ▶ Silvia Pérez
- ▶ sperez@uno.edu.ar

- ▶ Comité académico:
- ▶ Monica Giuliano
- ▶ mgiuliano@uno.edu.ar

**Agregar INFO en NOVIEMBRE
para indicar estado actual y poder
buscar tutor en el siguiente link**

<https://docs.google.com/spreadsheets/d/14wlnlUllt7FAoyoxyKAPFmDnwGW0Tmul76M4rWMhVwA/edit?gid=372543135#gid=372543135>